“시간이 아깝지 않은”

SK네트웍스 Family AI캠프 교재7

강사 이영배

18. 모델 검증 및 평가

Confusion matrix(혼돈 행렬, 오차 행렬)

- 개념

: 분류 모델의 예측 성능을 측정하기 위해 실제 정답과 모델이 예측한 값을 비교하여 표현한 2×2 행렬

		예측 결과	
		TRUE	FALSE
실제 정답	TRUE	TP (True Positive)	FN (False Negative)
	FALSE	FP (False Positive)	TN (True Negative)

분류 평가 지표 : 정확도(Accuracy)

- 개념

  : 전체 예측 데이터 건수 중, 모델이 실제 정답을 맞힌 건수의 비율

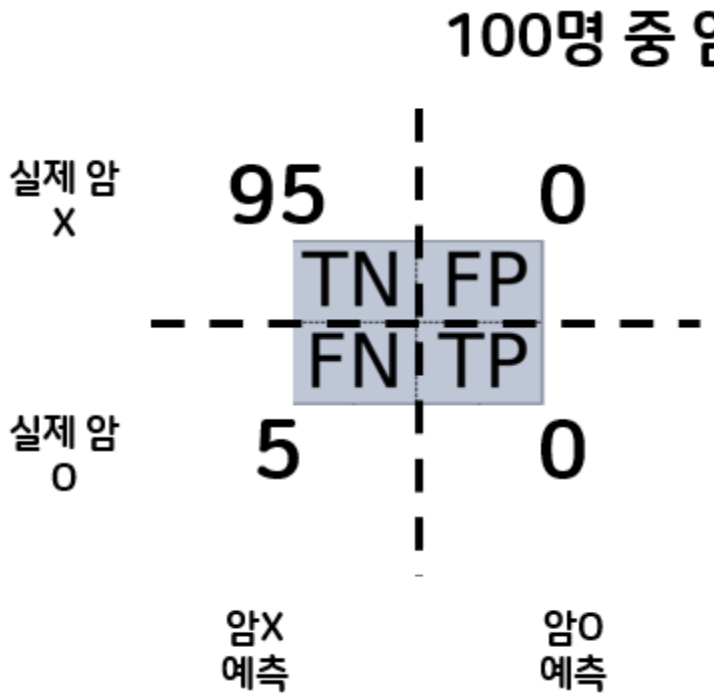
TP	FN
FP	TN

$$\text{Accuracy} = \frac{\text{TP} + \text{TN}}{\text{TP} + \text{TN} + \text{FP} + \text{FN}}$$ **(전체 중에 정확히 맞춘 비율)**

분류 평가 지표 : 정확도(Accuracy)

- 한계

: 데이터의 불균형 상태(예: 암 환자 5%, 정상 95%)에서는 모델이 아무 연산 없이 "전부 정상"이라고만 찍어도 정확도가 95%가 나오는 수학적 왜곡 발생



$$\text{Accuracy} = \frac{\text{TP} + \text{TN}}{\text{TP} + \text{TN} + \text{FP} + \text{FN}}$$

$$\frac{95}{100}$$

분류 평가 지표 : 재현율(Recall)

- 개념

: 실제 정답이 Positive(양성)인 것들 중, 모델이 Positive라고 맞힌 비율

모델의 예측

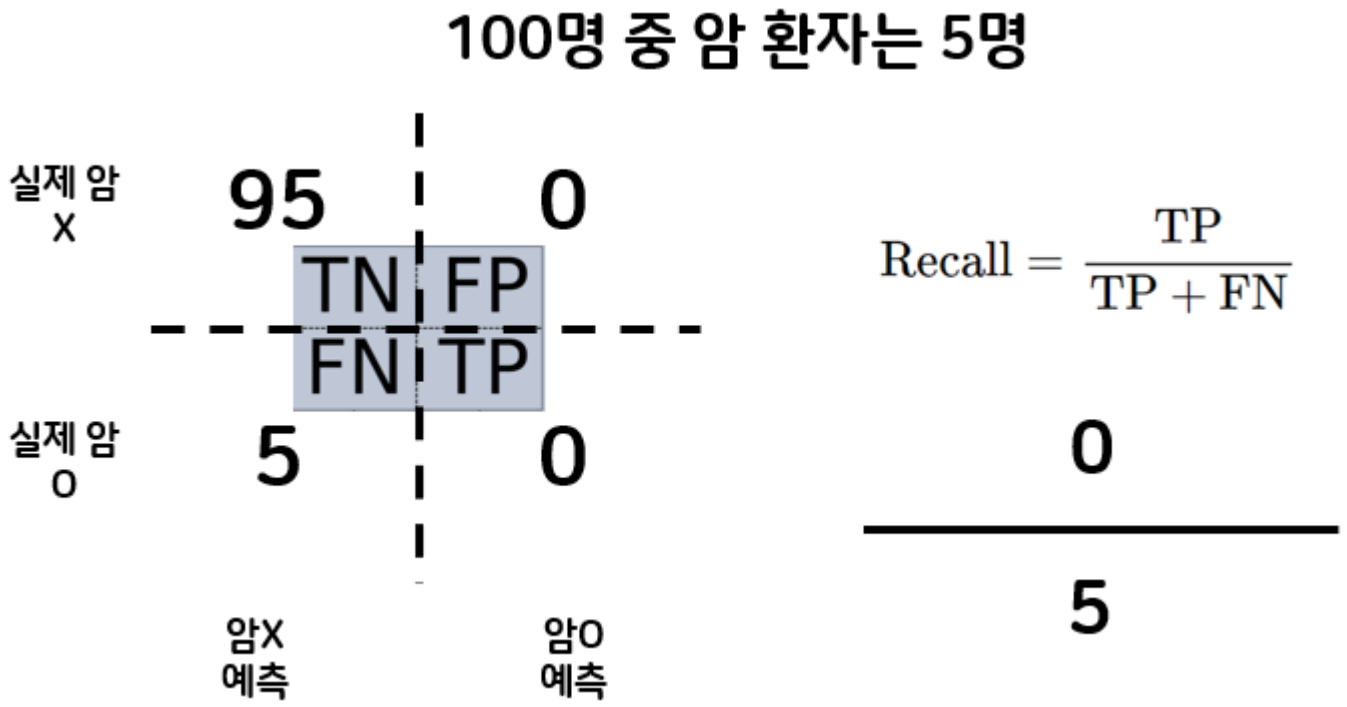
정답

TP	FN
FP	TN

$$\text{Recall} = \frac{\text{TP}}{\text{TP} + \text{FN}}$$

(실제 정답 중에 정확히 맞춘 비율)

분류 평가 지표 : 재현율(Recall)



$$\text{Recall} = \frac{\text{TP}}{\text{TP} + \text{FN}}$$

$$\frac{0}{5}$$

분류 평가 지표 : 정밀도 (Precision)

- 개념

: 모델이 Positive(양성)라고 예측한 것들 중, 실제 정답이 Positive인 비율

모델의 예측

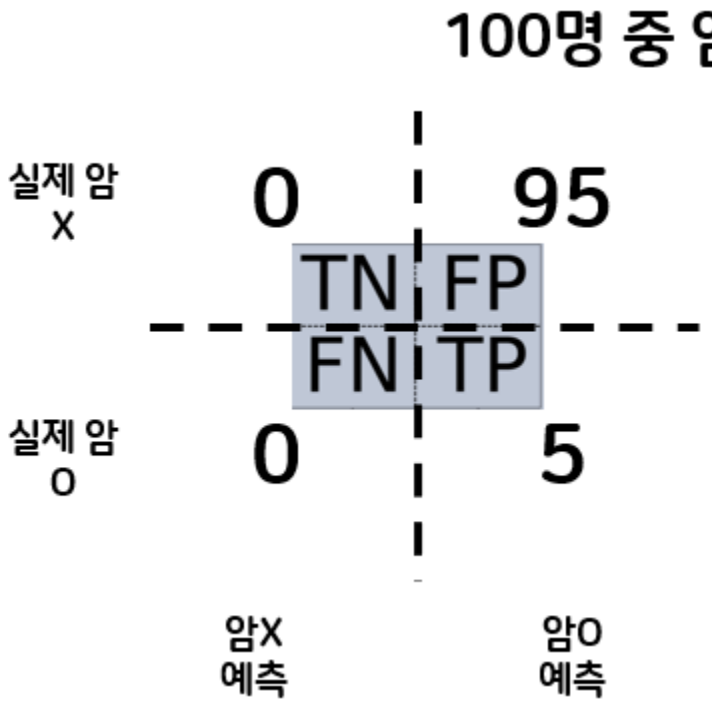
정답

TP	FN
FP	TN

$$\text{Precision} = \frac{\text{TP}}{\text{TP} + \text{FP}}$$

(정답으로 예측한 것 중에서 실제로 맞춘 비율)

분류 평가 지표 : 정밀도 (Precision)



$$\text{Precision} = \frac{\text{TP}}{\text{TP} + \text{FP}}$$

$$\frac{5}{100}$$

분류 평가 지표 : F1-Score (조화평균)

- 개념

1) 정밀도(Precision)와 재현율(Recall)의 조화평균

2) 수식

$$\text{F1 Score} = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}$$

3) 왜 일반 산술평균을 쓰면 안 되는가?

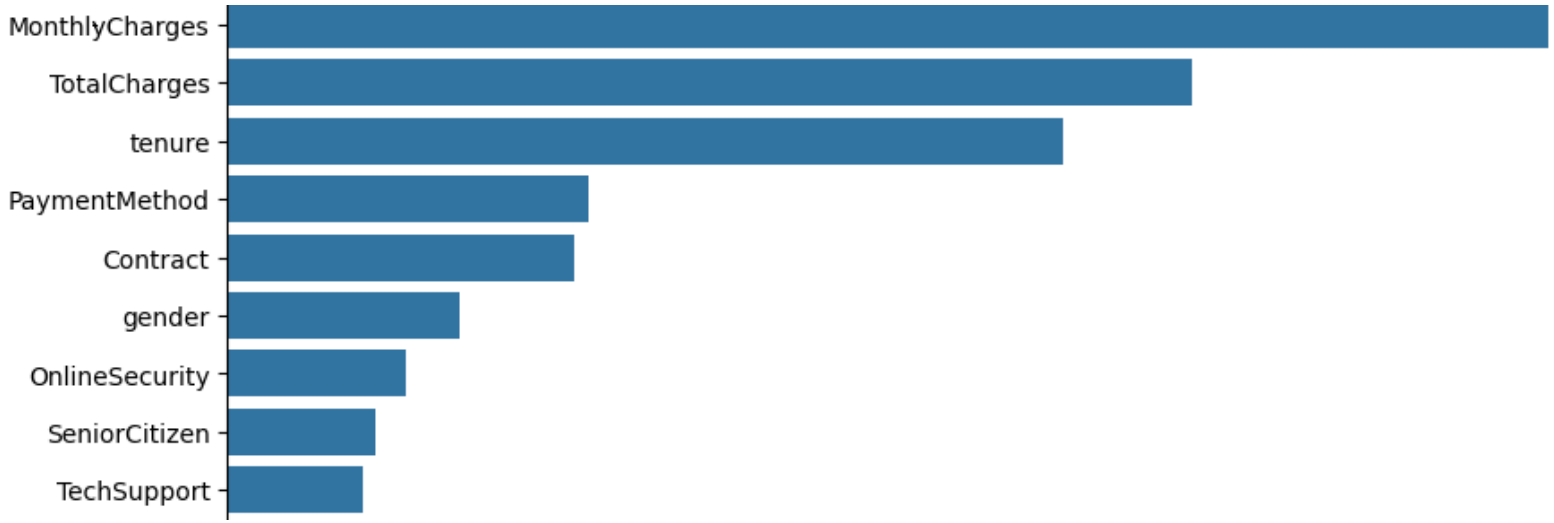
① 만약 어떤 엉터리 모델의 정밀도가 100%(1.0), 재현율이 0%(0.0)라고 가정해 봅시다.

② 산술평균 : 1.0 + 0.0 / 2 = 0.5 (50%)

③ 조화평균 : (2 × 1.0 × 0.0) / (1.0 + 0.0) = 0.0 (어느 한쪽이 0이면 최종 점수도 무자비하게 0으로 통제하여 불균형의 왜곡 현상을 완벽히 차단함)

특성 중요도(Feature Importance)

- 개념 : 학습이 완료된 모델이 예측을 수행할 때, 어떤 특성(feature)을 다른 특성보다 더 중요하게 정답의 근거로 사용했는지 알려주는 지표이다.
- 용도
  - 블랙박스인 모델의 내부를 들여다보고, "이 모델은 무엇을 근거로 이런 판단(예측)을 내렸을까?" 라는 질문에 대한 단서를 얻는 것이다.



특성 중요도(Feature Importance)

- 특성 중요도의 종류 (분석 데이터 및 측정 방식 기준)

1) 내장 특성 중요도 (학습용 데이터 기준): 모델 학습(Train) 과정에서 각 특성(컬럼)이 노드 분할에 얼마나 기여했는지 평균적인 불순도 감소량을 기반으로 측정하여 컬럼별 기여도를 측정하고 표시하는 기법이다.
2) 순열 특성 중요도 (평가용 데이터 기준): 학습을 마친 모델에 평가 데이터(Test)를 넣고 예측을 수행할 때, 특정 컬럼의 데이터를 무작위로 섞었을 때 모델의 성능이 얼마나 하락하는지 측정하여 컬럼의 실제 기여도를 측정하는 기법이다.

특성 중요도(Feature Importance)

- 과적합(Overfitting) 유무 판별을 통한 모델 검증

1) 검증 목적: GridSearchCV 등으로 최적화된 모델이 단순히 학습 데이터를 암기한 것인지, 아니면 새로운 실전 데이터에도 적용 가능한지 판별하기 위해 두 종류의 특성 중요도를 반드시 교차 대조해야 한다.

2) 판정 기준

① 안정적으로 검증된 모델 (일반화 성공)

: 학습용 데이터 분석 결과(내장 중요도)와 평가용 데이터 분석(순열 중요도) 결과의 상위권 특성 순위가 유사하게 유지되는 경우이다. 이는 모델이 실전에서도 올바른 근거로 예측하고 있음을 증명한다.

② 과적합된 불량 모델 (일반화 실패)

: 학습 데이터에서 중요도가 매우 높게 계산된 특성이, 평가 데이터(순열 중요도) 검증에서는 기여도가 폭락하거나 음수(-)로 떨어지는 경우이다. 이는 모델이 학습 데이터의 노이즈까지 암기했다는 증거이므로 실전 배포를 중단하고 재학습해야 한다.

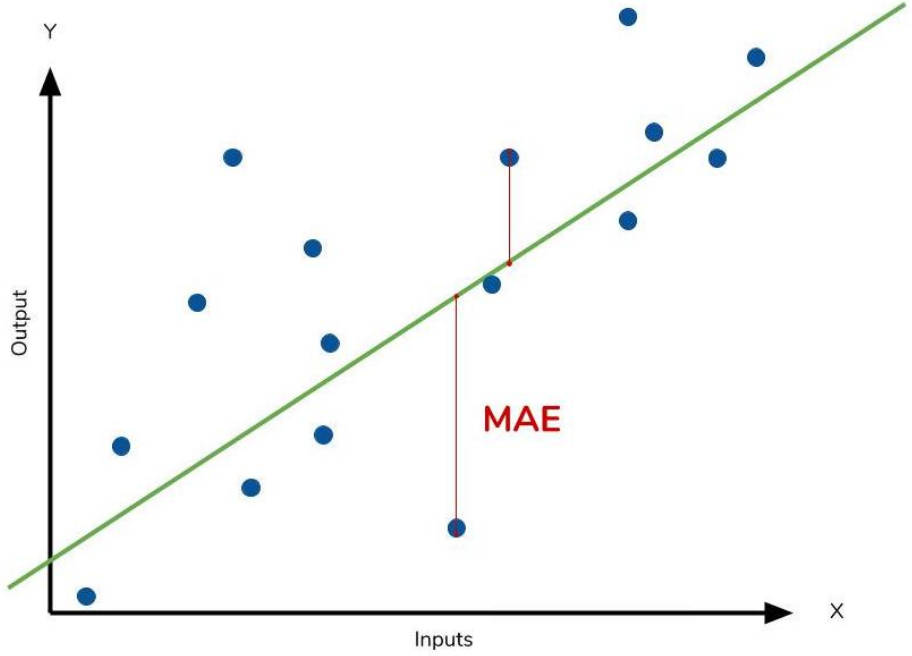
분류 모델 성능 고도화 검증 및 평가 종합 실습

회귀 평가 지표 : 평균 제곱근 오차(RMSE : Root Mean Squared Error)

- RMSE

  1) 개념: 평균 제곱 오차(MSE)에 Root를 씌운 것

  2) 평균 제곱 오차(MSE : Mean Squared Error): 모델의 예측 값과 실제 값의 차이의 제곱을 모두 더하여 평균을 구한다



$$MSE = \frac{\sum(y - \hat{y})^2}{n}$$

$$RMSE = \sqrt{\sum_{i=1}^{n} \frac{(\hat{y}_i - y_i)^2}{n}}$$

회귀 모델 성능 고도화 검증 및 평가 종합 실습


MISSION:
COMPLETE